Auditável por construção

E N T H

Alexandre Pinto Calaes
PPGEGC/UFSC



A IA alucina. 2.217



$$softmax(z)_i = e^{z_i} / \Sigma_j e^{z_j}$$

$$P(y_t \mid y_{<t}, x)$$

EUA 1.514

Lei 8.112/1990
ADI 2.958
art. 37, XXXIII

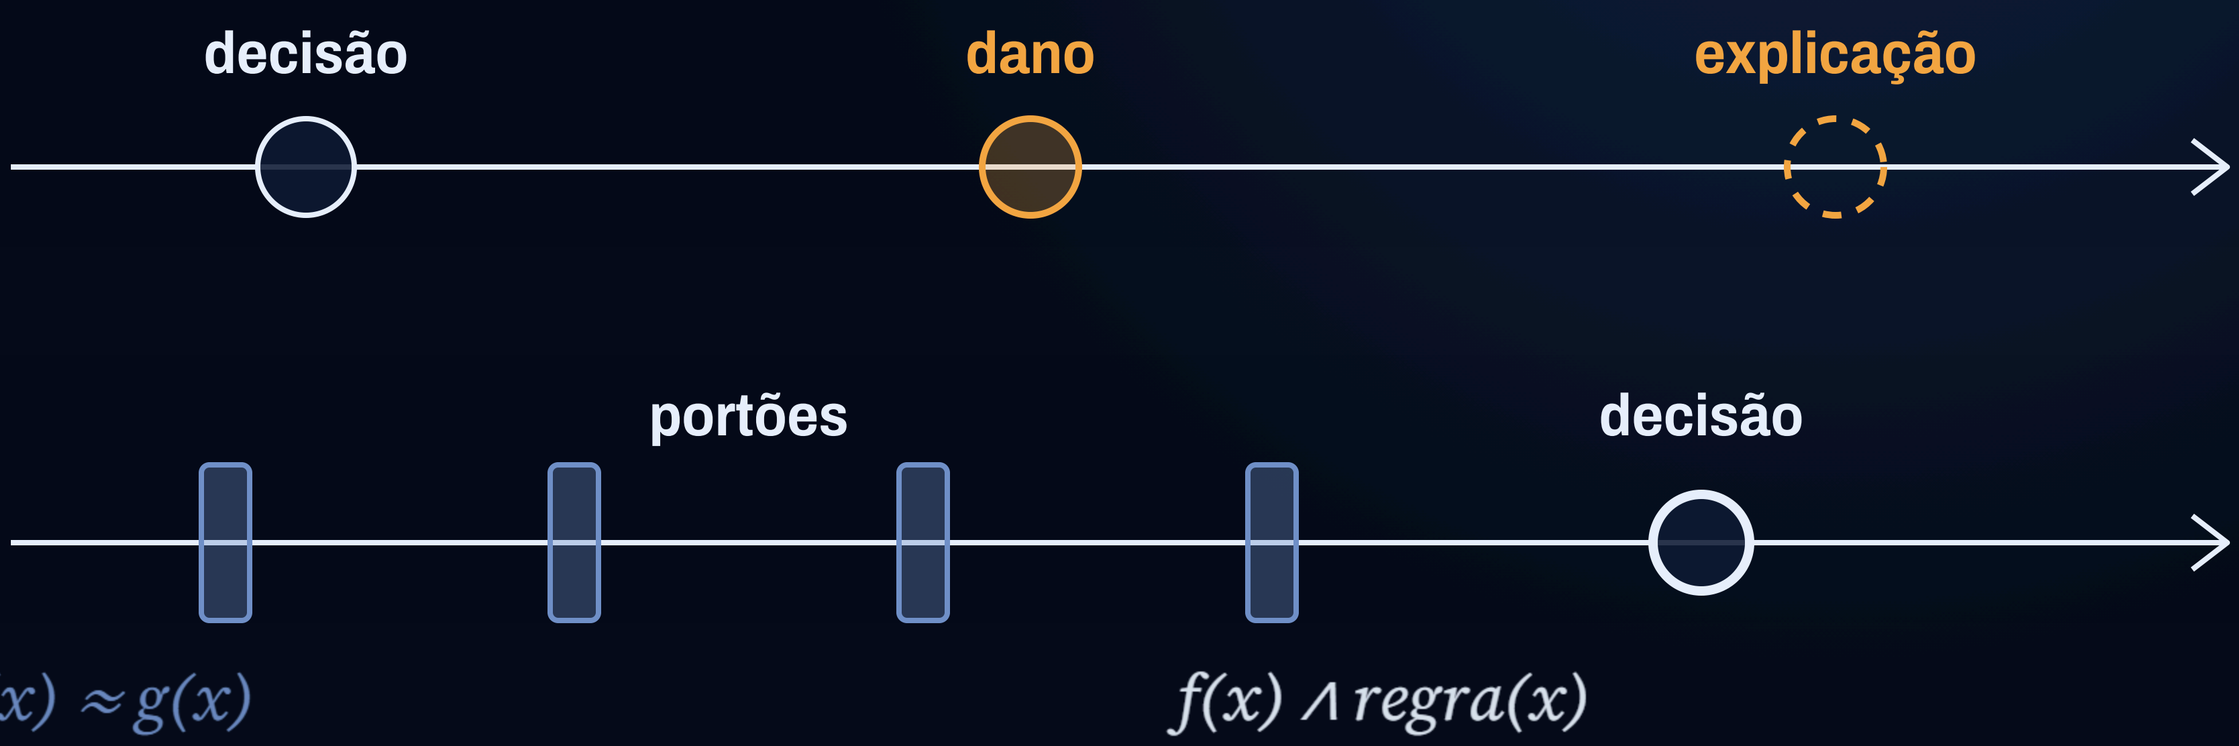
Brasil 41

casos em tribunais, 25/10/2026; fórmula e rede são ilustração didática

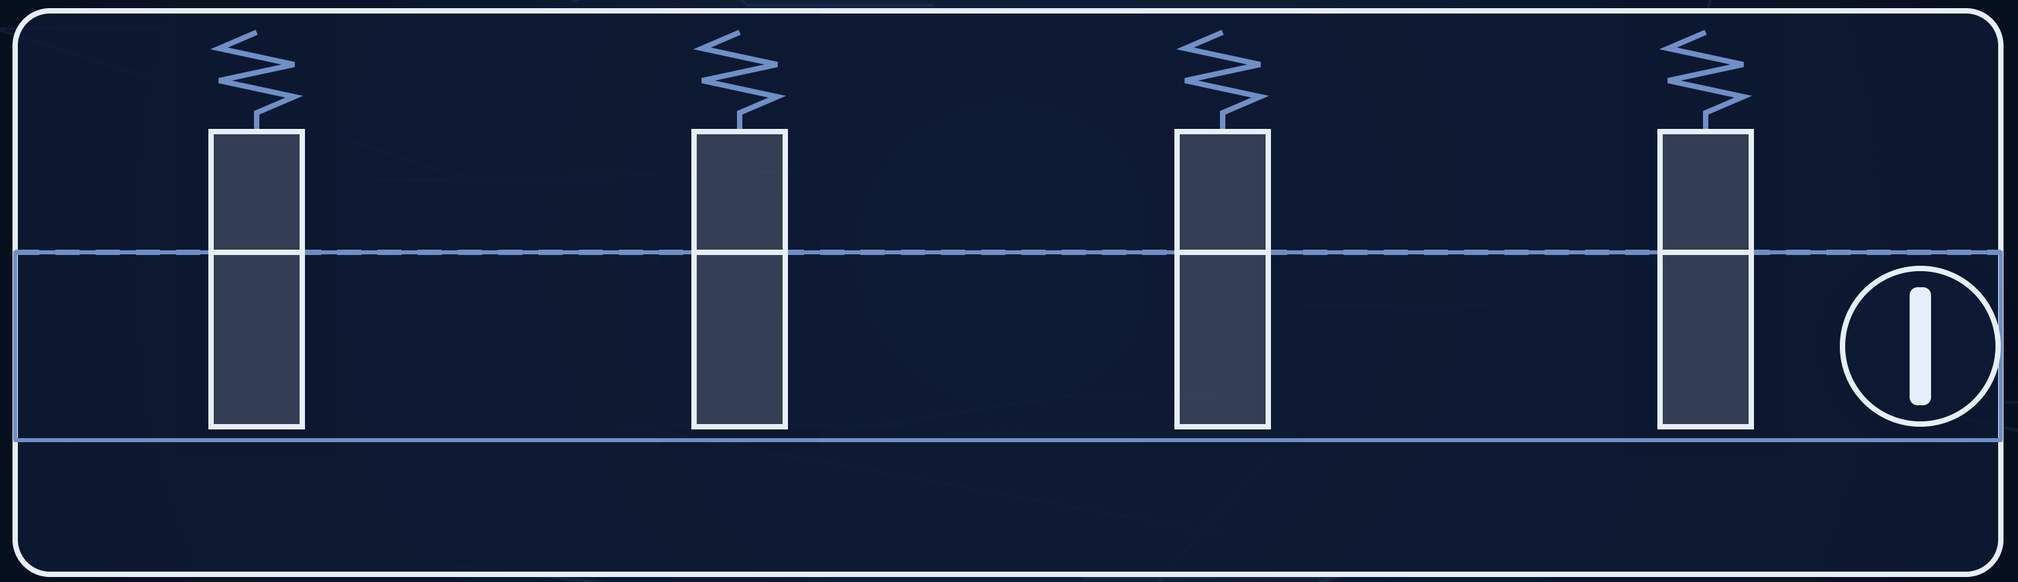
Explicar depois não basta







E∧N∧T∧H



admissivel(Y) :- evidencia(Y), norma(Y), rastro(Y).

liberada(Y) :- admissivel(Y), humano(Y).

especificação formal, não garantia experimental

Neural propõe. Simbólico verifica.

CALAIS



Recuperar → Gerar → Verificar → Registrar → Aprovar

$$V(y) = N(y, \Omega) \wedge T(y)$$

laço gerar, verificar, corrigir (laço agêntico); registro em padrão W3C PROV

Citāre

conferiu este artigo



```
:Citacao :temDOI "..." .
:Afirmacao :apoiadaPor :Fonte .
```

$$R_k(q) = TopK_{d \in D}\, s(q, d)$$

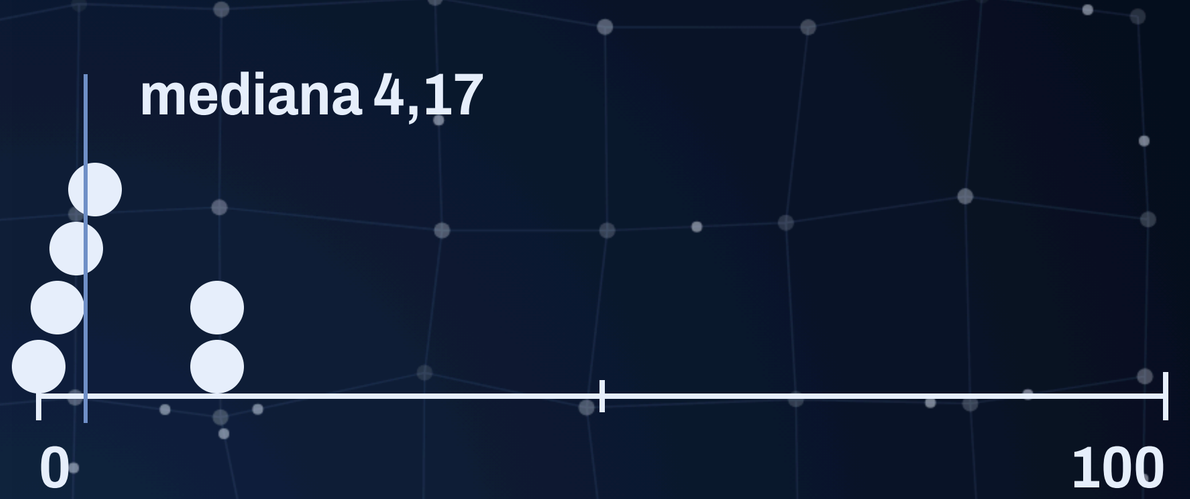


grafo de conhecimento; dados do CBMSC/ESAG não avaliam o Citāre

Textura: Carolina Prysyazhnyuk, CC BY-SA 2.0 (Card catalogue drawers)

191 dias

9.054 envios



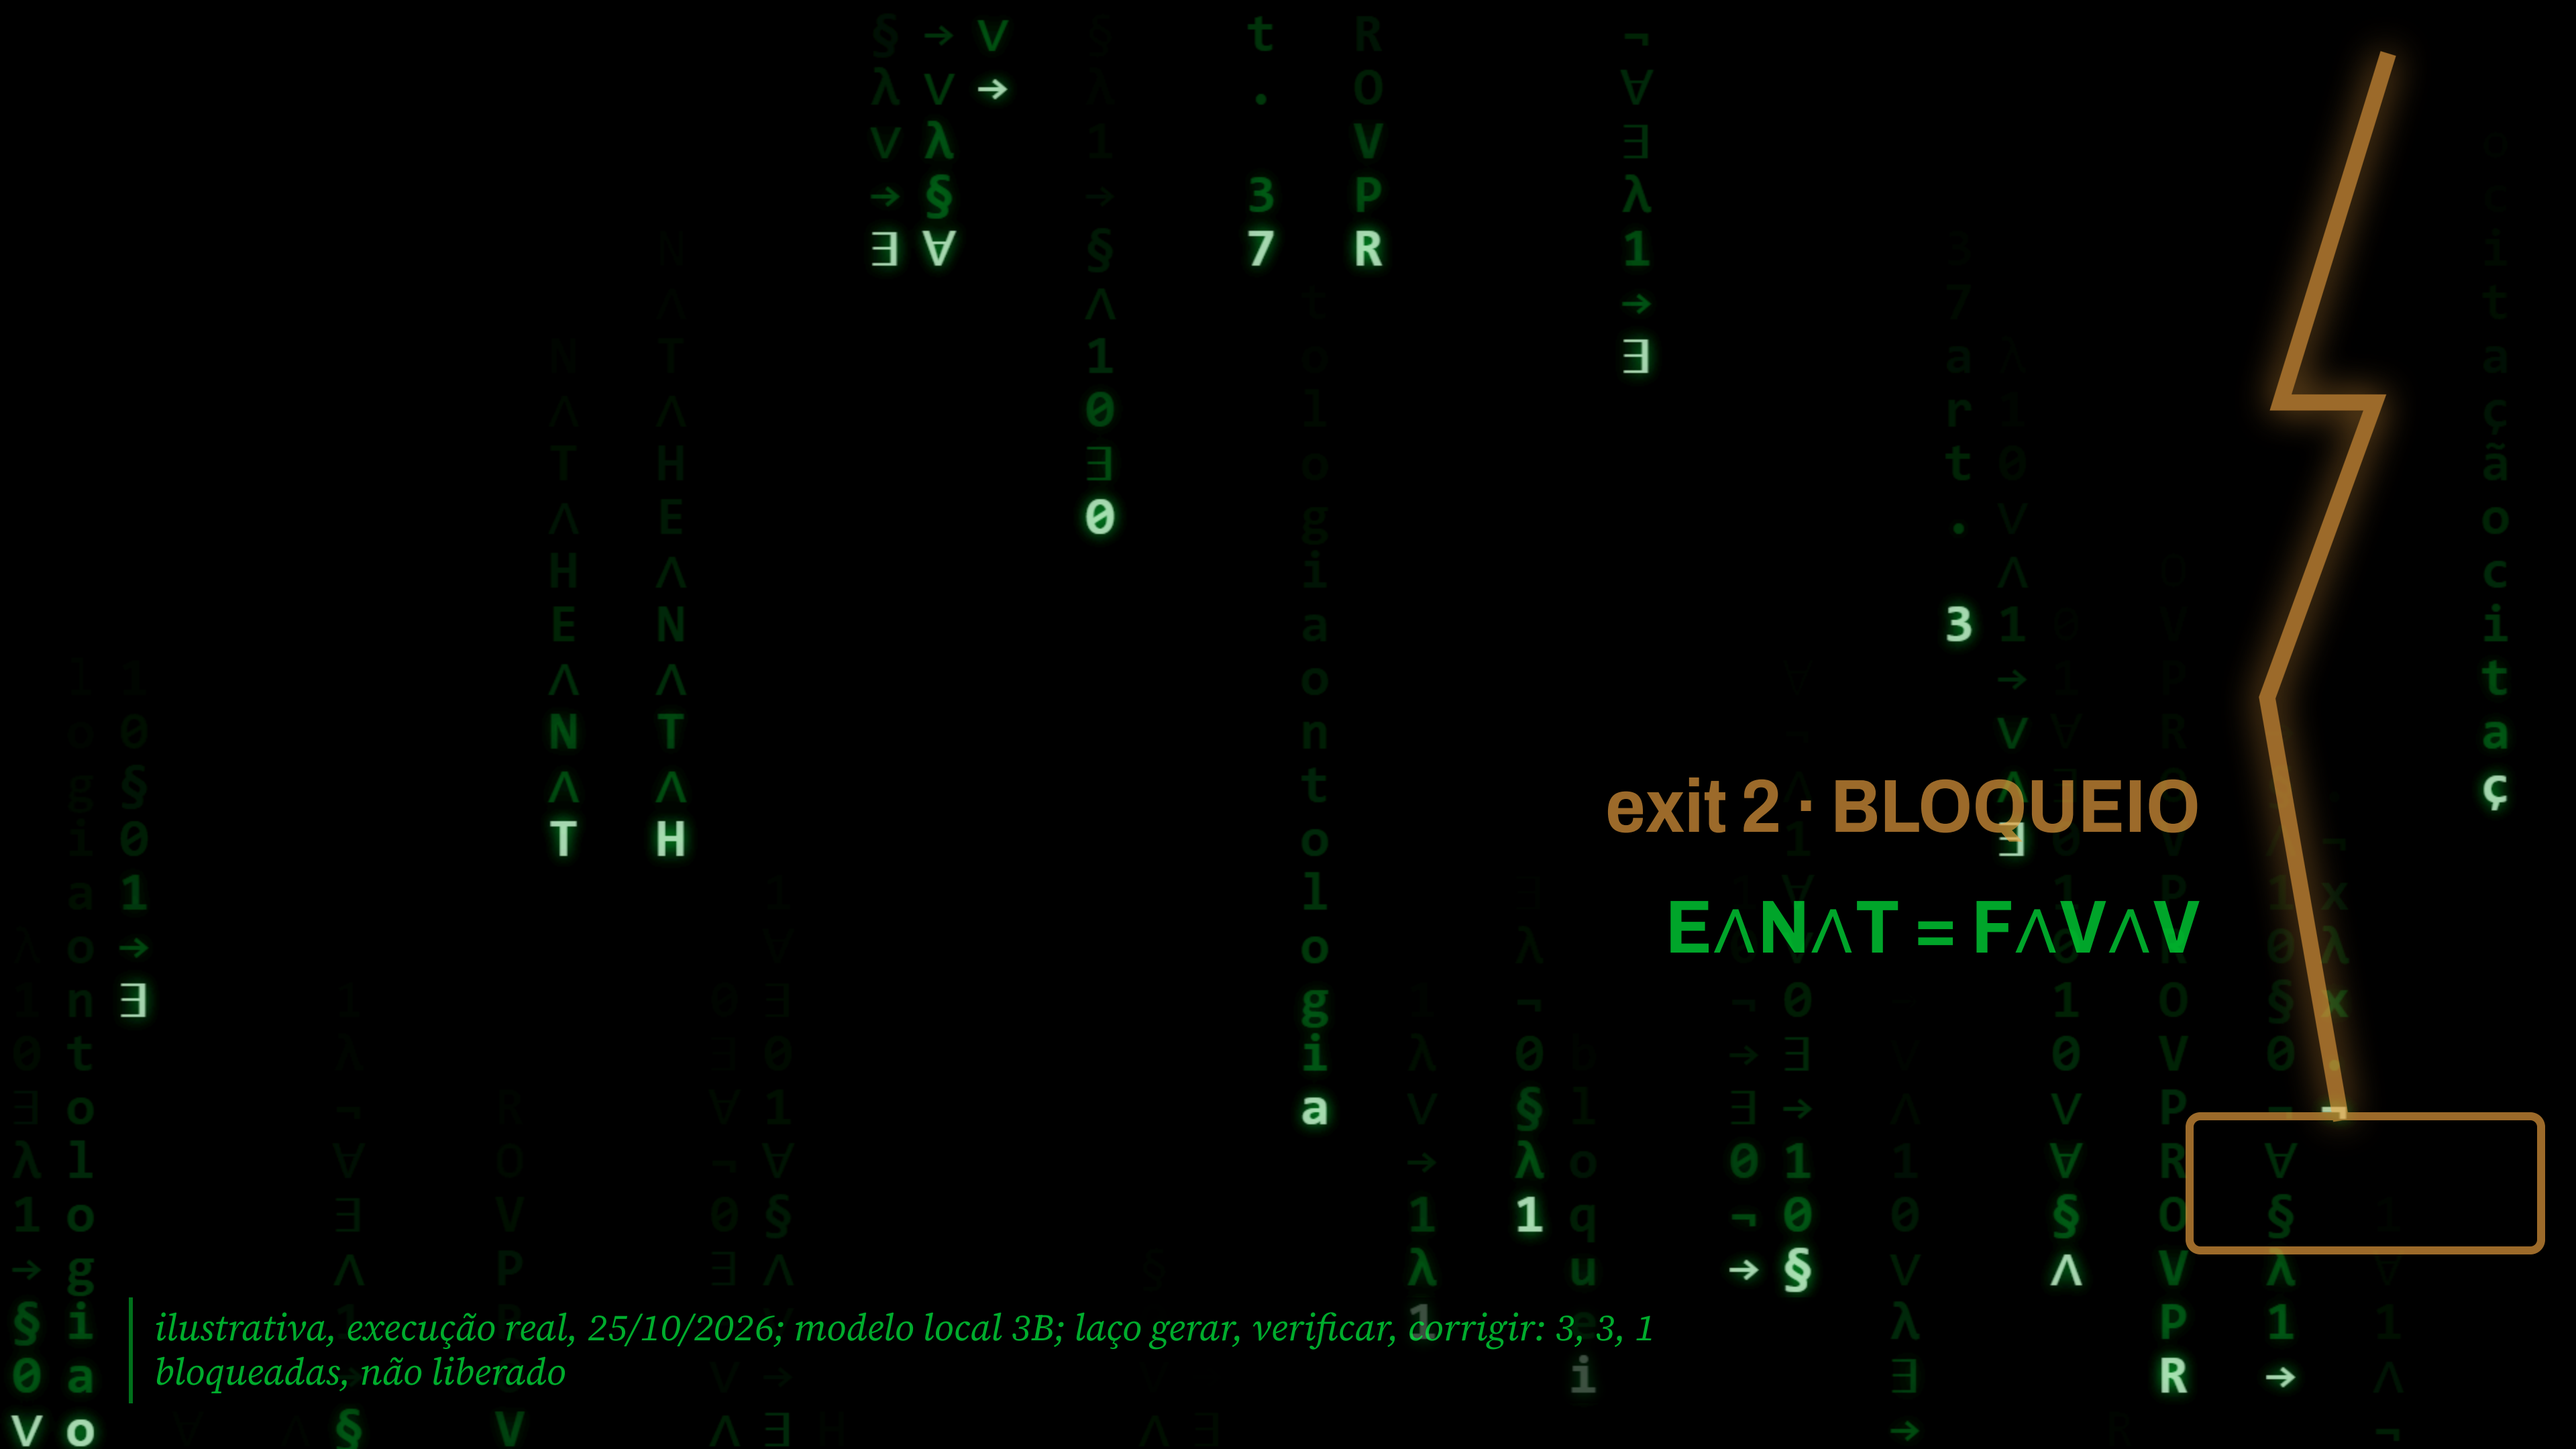
$$TLX = (1/6)\ \Sigma_{i=1}^{6}\ s_i$$

CBMSC	ESAG

2.813 sem sucesso

evidência exploratória, Santa Catarina; 2.813 envios sem sucesso não são bloqueios

Textura: DAR7, CC0 (Corpo de Bombeiros Militar de SC)



ilustrativa, execução real, 25/10/2026; modelo local 3B; laço gerar, verificar, corrigir: 3, 3, 1 bloqueadas, não liberado

Agente = modelo + harness



446 2026

desempenho	89,7%
custo	4%

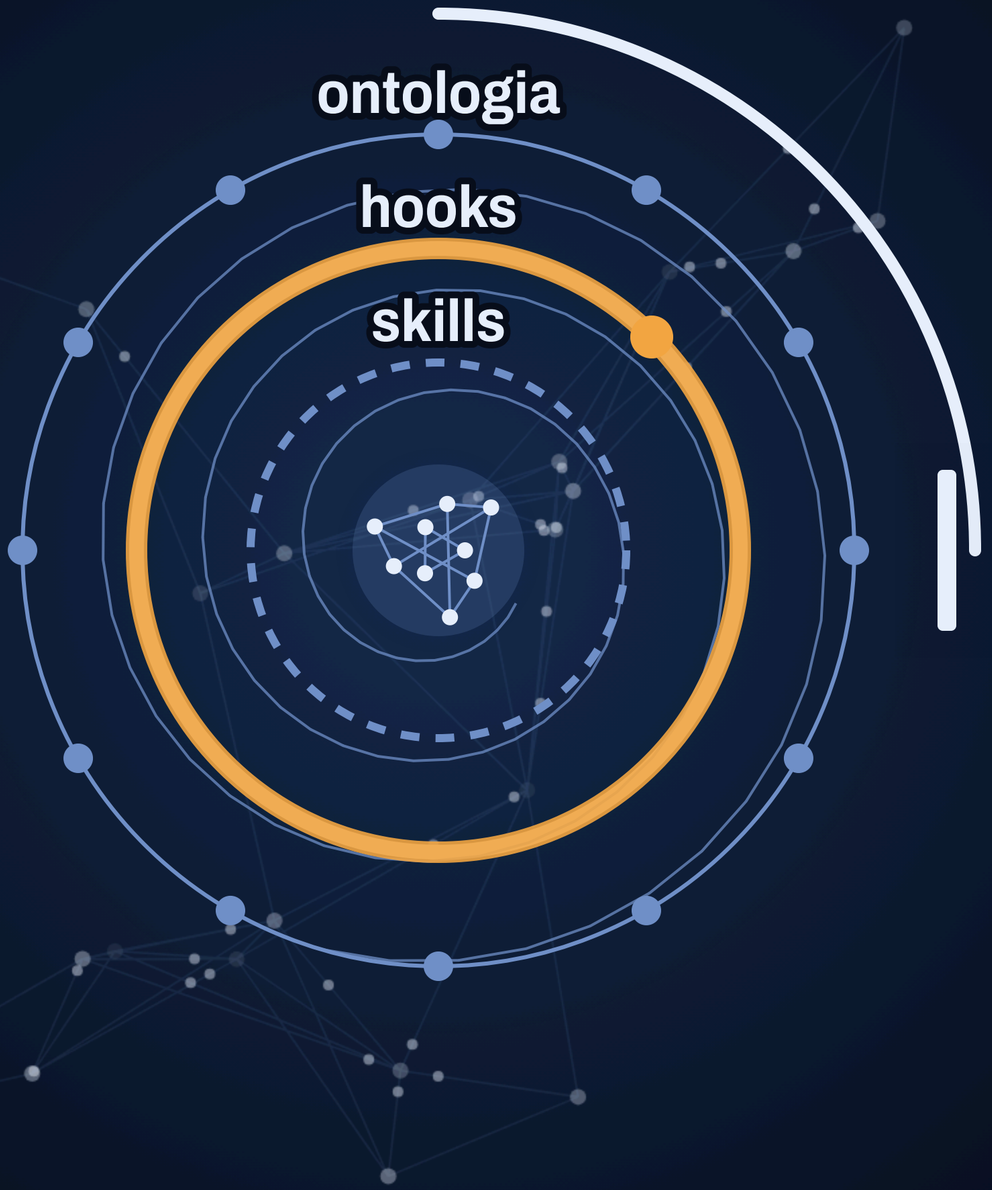
contagem do autor (2025 e 2026); CMU em preprint

HNV

especialista
escreve
regras

hipótese





Próximo: estudo pareado

$$\Delta = métrica(arquitetura) - métrica(base)$$



evidência exploratória, situada em Santa Catarina; HNV é hipótese

Auditável por construção.

E N T H



Alexandre Pinto Calaes
acalaes@gmail.com

Perguntas difíceis

Isso não é só RAG?

RAG recupera e o modelo gera. Aqui o hook confere cada citação contra a ontologia e bloqueia a que está fora. RAG jurídico ainda erra 17 a 33% nos preprints.

E o raciocínio?

O harness confere citações, não raciocínio. Por isso a decisão final é humana.

E a LGPD?

A demonstração usa modelo local. Tratamento de dados pessoais não foi avaliado: é limite declarado.

Método DSR

Artefato
Harness com quatro condições: evidência, norma, rastro e humano.

Demonstração
Cena 1 sem harness, cena 2 com harness, ontologia e hook.

Avaliação
Exploratória, em Santa Catarina. Estudo pareado ainda por fazer.

Tabela 3 do artigo

Referências

Referências

Fontes das afirmações do deck e referências do artigo #160.

Fontes das afirmações do deck (clique para abrir a gaveta)

- charlotin Charlotin, AI Hallucination Cases Database.
- dahl Dahl et al. (2024), Large Legal Fictions, versão preprint arXiv (a página do periódico cita 69–88%).
- magesh Magesh et al. (2025), Hallucination-Free?, versão preprint arXiv (o periódico cita 'mais de 17%').
- rudin Rudin (2019), Nature Machine Intelligence 1, 206–215, citado no artigo #160 (Discussão).
- art-citare Artigo #160, declaração de uso de IA.
- art-logs Artigo #160, Seção de resultados (CBMSC).
- art-nasa Artigo #160, Seção de resultados e Tabela 5.
- arxiv-count Contagem do autor na API do arXiv; 2025 conferido título a título, 2026 amostra de 25 títulos.
- cmu Yang, Kästner et al. (2026), Better Harnesses, Smaller Models.
- capex CNBC (2026) e estimativas de analistas; sem fonte primária por empresa.
- mit MIT NANDA (2025), The GenAI Divide, relatório preliminar.
- art-tab1 Artigo #160, Seção 2.1, Tabela 1 (síntese dos autores, não validada pelos autores citados nem resultado experimental).
- art-eq Artigo #160, Seção 3.1, Equações 1 a 3.
- art-limpe Artigo #160, Seção 2.2, Tabela 2 (síntese dos autores).
- prov-dm Moreau & Missier (Eds.) (2013), PROV-DM: The PROV data model, W3C, citado no artigo #160.
- art-arq Artigo #160, Seção 3.1, Figura 1 (redesenhada neste painel a partir do texto).

Agenda de pesquisa

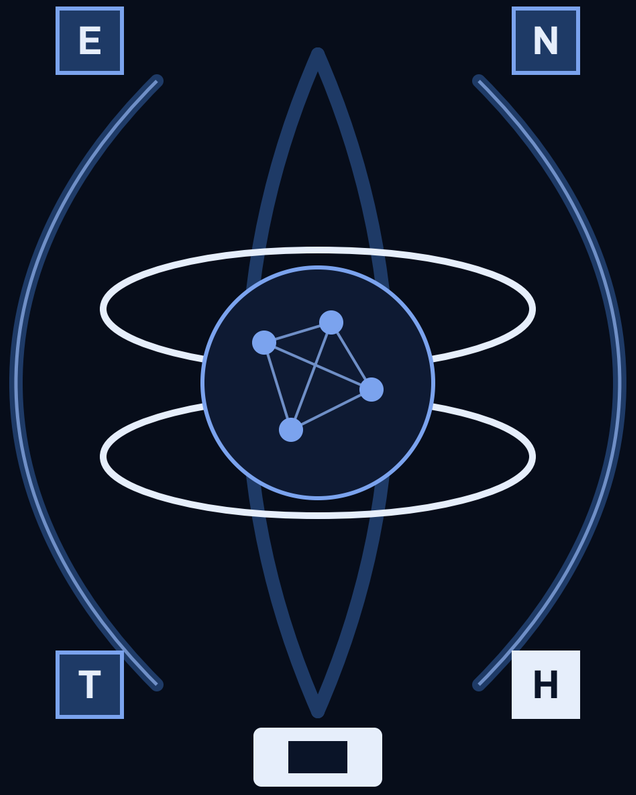
Estudo pareado
Quatro condições: manual, LLM puro, RAG e arquitetura completa.

Ontologia validada
Hoje são 18 instâncias pendentes de validação por especialistas.

Outros domínios
Propostas, não resultados: pareceres administrativos, escrita científica, boletins de ocorrência de bombeiros.

O que cada parte do harness representa

Legenda da cena 3D da capa; é uma metáfora visual, não um diagrama de código.



- **Núcleo luminoso.** modelo neural: lê e escreve linguagem natural; propõe, não decide
- **Faixas curvas.** skills e instruções: guia macio, orienta o modelo mas não obriga
- **Anéis rígidos.** hooks: regra dura, executada pelo harness (bloqueia, não negocia)
- **Quatro ancoragens E N T H.** evidência, norma, rastro e humano: as quatro condições do artigo
- **Fivela.** aprovação humana: só a pessoa fecha e libera

- Mapa guia macio × regra dura
- Artigo: Equações 2 e 3

Metáfora visual da capa; o mapa guia macio × regra dura vem do README da demonstração.

As quatro condições e as cores

Cada coluna é um pino da fechadura: falta um e o resultado não abre.

E

Evidência

O que sustenta a afirmação: documentos recuperados e ligados à resposta.

E(y, R)

N

Norma

As regras aplicáveis conferem a resposta; o sistema pode bloquear.

N(y, Ω)

T

Rastro

O caminho fica registrado: fontes, verificações e decisões.

T(y)

H

Humano

Quem decide manter, modificar ou rejeitar a recomendação.

H(y)

Azul: verificado e registrado

Âmbar: onde o sistema para

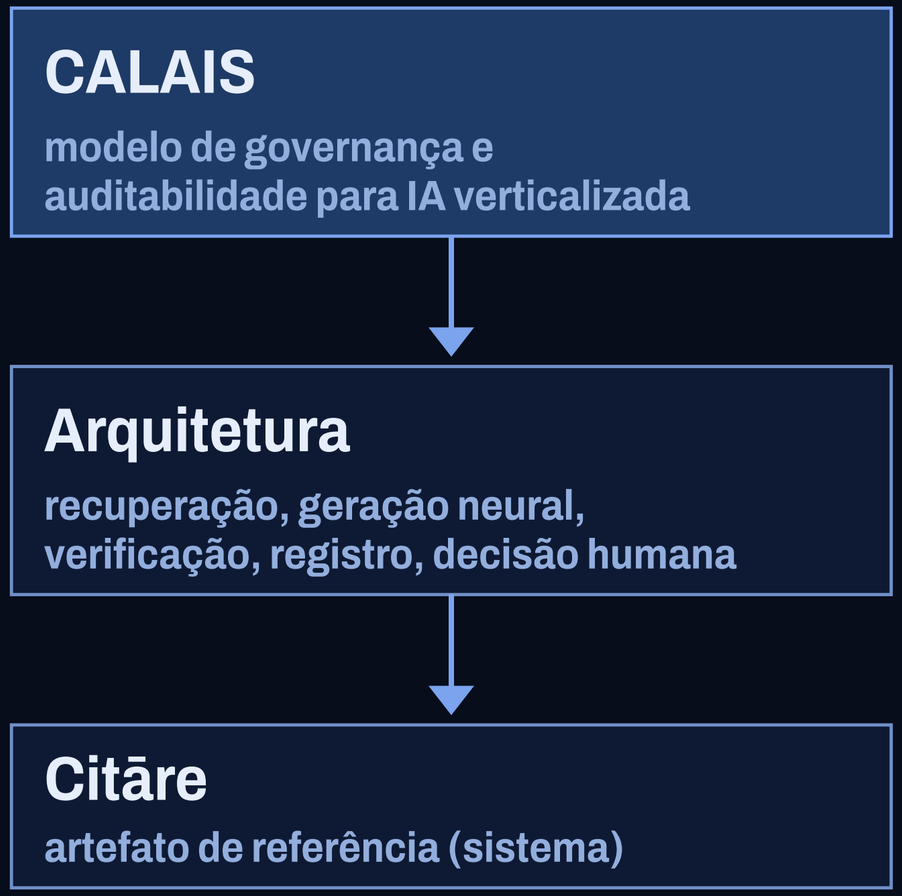
Luz clara: decisão humana

• Artigo: Equações 2 e 3

Símbolos conforme as Equações 2 e 3 do artigo (Seção 3.1). Âmbar aparece apenas para erro ou bloqueio.

Ficha do artigo

Título (EN)	*Neurosymbolic Artificial Intelligence and Knowledge Engineering: Beyond Hallucinations and Auditable Decisions in the Intelligent State*
Artigo	#160 · CIKI 2026 · apresentação em 28/10/2026
Autor	Alexandre Pinto Calaes · PPGEGC/UFSC
Método	Design Science Research (DSR), em seis ciclos rastreáveis
Evidência	Aplicações prévias no CBMSC e na ESAG/UDESC: exploratória, em Santa Catarina
Apoio	CAPES, Finance Code 001



- Artigo: método DSR
- Artigo: escopo da evidência

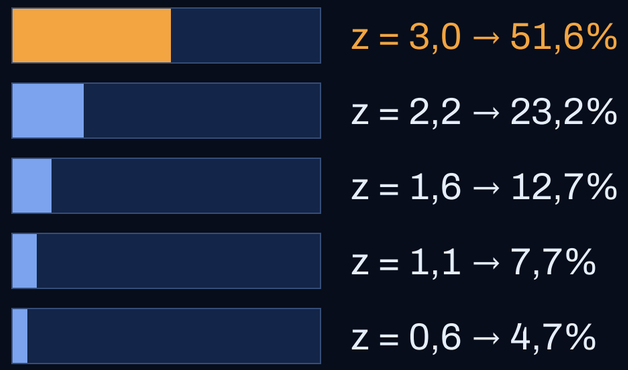
Título e dados do artigo #160 (versão final). Autoria e vínculo conforme o artigo e a capa.

Por que um modelo de linguagem alucina: ele escolhe o plausível, não o verdadeiro

$$softmax(z)_i = \frac{e^{z_i}}{\sum_{j=1}^{K} e^{z_j}}$$

$$P(y_t \mid y_{<t}, x) = softmax(W\, h_t)_{y_t}$$

Qual inciso do art. 37 trata de nepotismo? Valores z hipotéticos; probabilidades calculadas pela fórmula.



- A rede dá uma nota *z* a cada palavra possível; a softmax transforma as notas em probabilidades que somam 100%.
- O modelo escreve o que tem maior probabilidade ou sorteia entre as mais prováveis.
- Nada na fórmula consulta se a fonte existe: um inciso inexistente pode ser a opção mais provável.

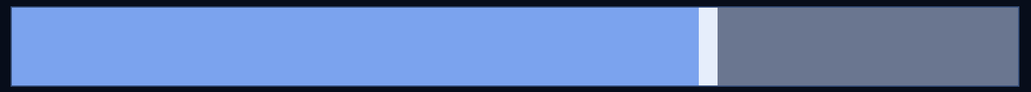
• Huang et al. (2025)
• Definição da softmax

Explicação didática. Huang et al. (2025) é a revisão sobre alucinação em modelos de linguagem citada no artigo.

ilustrativo

Casos de alucinação em tribunais e taxas em testes

2.217 casos (25/10/2026)



País	Casos	Parcela
EUA	1.514	68,3%
Brasil	41	1,8%
Demais países	662	29,9%

Demais países = total − EUA − Brasil (cálculo do autor). Base mantida por Damien Charlotin.

Taxa de erro em perguntas jurídicas verificáveis

Modelos de linguagem gerais (Dahl et al.)



58–88%

Ferramentas jurídicas com RAG (Magesh et al.)



17–33%

0 25% 50% 75% 100%

Cada faixa vai da menor à maior taxa entre os sistemas testados. Nas versões publicadas em periódicos, os limites divergem (69–88% e “mais de 17%”).

- Charlotin (2026)
- Dahl et al. (2024)
- Magesh et al. (2025)

Charlotin, AI Hallucination Cases Database, consultada em 25/10/2026. Dahl e Magesh: faixas das versões preprint (arXiv).

preprint

Checagem manual: o que o modelo local escreveu sem harness

Modelo local de 3 bilhões de parâmetros, três rodadas; conferência em fonte oficial, 25/10/2026.

Rodada	Citação do modelo	Veredito	O que a fonte oficial mostra
1 e 2	art. 37, inciso XXXIII, da Constituição	inexistente	O art. 37 vai só até o inciso XXII.
2	Decreto nº 4.653/2002, sobre nomeação de parentes	atribuição falsa	É de 27/03/2003, estrutura do Ministério do Turismo; não trata de nepotismo.
3	art. 37, inciso XXI, “proíbe o nepotismo”	atribuição falsa	O inciso XXI trata de licitação.
3	Lei nº 8.112/1990, “principal instrumento” contra nepotismo	lei real, sem base	Regime dos servidores civis da União; não se aplica a todos os entes.
3	ADI 2.958 do STF, como decisão sobre nepotismo	pertinência não comprovada	O número existe; o assunto cadastrado é outro (Agentes Políticos, Ministério Público).
2	Decisão do STJ, sem número	não verificável	Sem número não há como conferir; o verificador não pega referência vaga.

- Checagem manual (cena 1)
- Constituição, art. 37

Fonte: logs/cena1/checagem_manual.json. Nas três rodadas houve ao menos uma citação inexistente ou com conteúdo falso.

Tabela 1: o que cada abordagem entrega

Abordagem	Fundamentação externa	Regras executáveis	Proveniência	Controle humano	Limitação principal
LLM puro	Não inerente	Não inerente	Baixa ou não garantida	Depende da implementação	Alucinação e opacidade
XAI post-hoc	Não altera a fundamentação	Não assegura conformidade	Parcial	Apoia a interpretação	Fidelidade da explicação
Sistema simbólico	Depende da base de conhecimento	Forte	Alta, se registrada	Configurável	Rigidez e manutenção
RAG	Nativa na recuperação, não na fidelidade final	Não inerente	Possível, se as fontes forem preservadas	Depende da implementação	Erros de recuperação ou de citação
IA neurossimbólica	Integrável	Potencialmente forte	Depende da arquitetura	Configurável	Complexidade de integração e validação
Arquitetura proposta	Documentos recuperados e vinculados	Regras explícitas verificam e podem bloquear	Fontes, verificações e decisões registradas	Aprovação nos fluxos relevantes	Evidência ainda situada e sem linha de base comum

Artigo: Tabela 1

Rudin (2019)

Fonte do artigo: síntese dos autores a partir de Rudin (2019), Lewis et al. (2020), Moreau e Missier (2013) e Garcez e Lamb (2023). Não validada pelos autores citados.



Rudin (2019): o argumento sobre explicações a posteriori

Cynthia Rudin · 2019

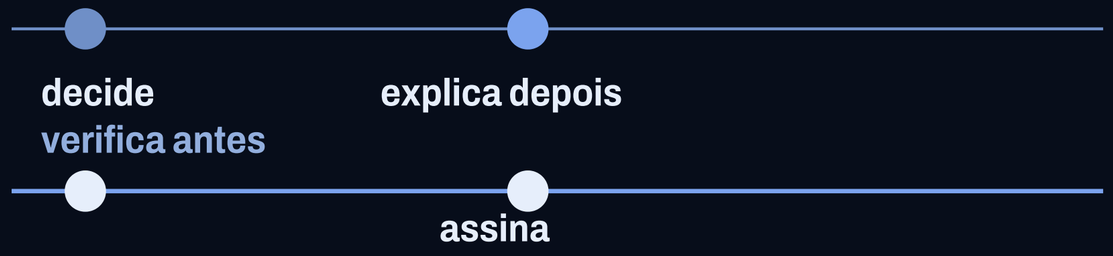
“Stop explaining black box machine learning models for high stakes decisions and use interpretable models instead.”

Nature Machine Intelligence, volume 1, páginas 206–215.

A autora recomenda modelos interpretáveis. O artigo usa o argumento sobre a fidelidade das explicações para defender mecanismos verificáveis.

O que o artigo aproveita

- Explicações a posteriori podem não representar a lógica real da caixa-preta em contextos críticos.
- Em decisões de alto impacto, elas não substituem mecanismos verificáveis.
- Explicar ajuda a compreender, mas não substitui evidência nem responsabilização.



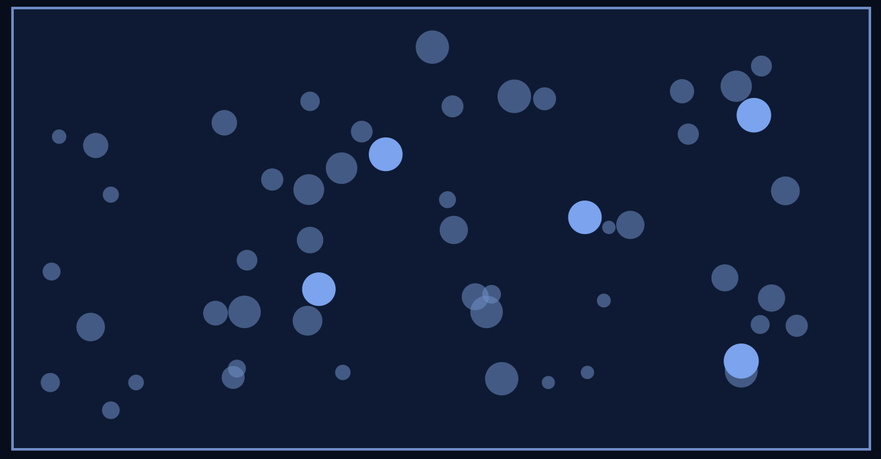
• Rudin (2019) • Artigo: Tabela 1

Referência: Rudin, C. (2019). Nature Machine Intelligence, 1, 206–215. As três linhas resumem o uso do argumento no artigo (Seções 1, 2.1 e 4.2).

Pino E: evidência recuperada

Equação 1: o sistema escolhe, na coleção, os k documentos mais relevantes para a consulta.

$$R_k(q) = TopK_{d \in D}\, s(q, d)$$



s(q, d)
relevância

documento d1 · s = 0,99
documento d2 · s = 0,97
documento d3 · s = 0,94
documento d4 · s = 0,92
documento d5 · s = 0,92
k = 5 · $R_k(q)$

pontos = documentos
tamanho = relevância
azul pulsante = top-k

q = consulta · D = coleção · $s(q, d)$ = relevância · $R_k(q)$ = os k documentos recuperados

Recuperar não prova que cada documento seja suficiente ou correto. Pontuações do desenho são ilustrativas.

Artigo: Equação 1

Equação 1 do artigo (Seção 3.1), baseada em Lewis et al. (2020). Dados do desenho: ilustrativos, não medidos.

Pino N: a norma e os princípios LIMPE

Constituição, art. 37: legalidade, impessoalidade, moralidade, publicidade e eficiência.

Princípio	Mecanismo relacionado	Evidência exigida
L Legalidade	Regras normativas e validação de conformidade	Norma aplicável, resultado da verificação e exceções
I Impessoalidade	Critérios uniformes e testes de consistência	Resultados para casos equivalentes e auditoria de viés
M Moralidade	Responsabilização e registro de intervenções	Autor, justificativa, alterações e decisões humanas
P Publicidade	Explicação, proveniência e contestabilidade	Fontes, regras e trajetória acessíveis, conforme sigilo e proteção de dados
E Eficiência	Automação assistida e recuperação documental	Tempo, custo, qualidade e retrabalho medidos comparativamente

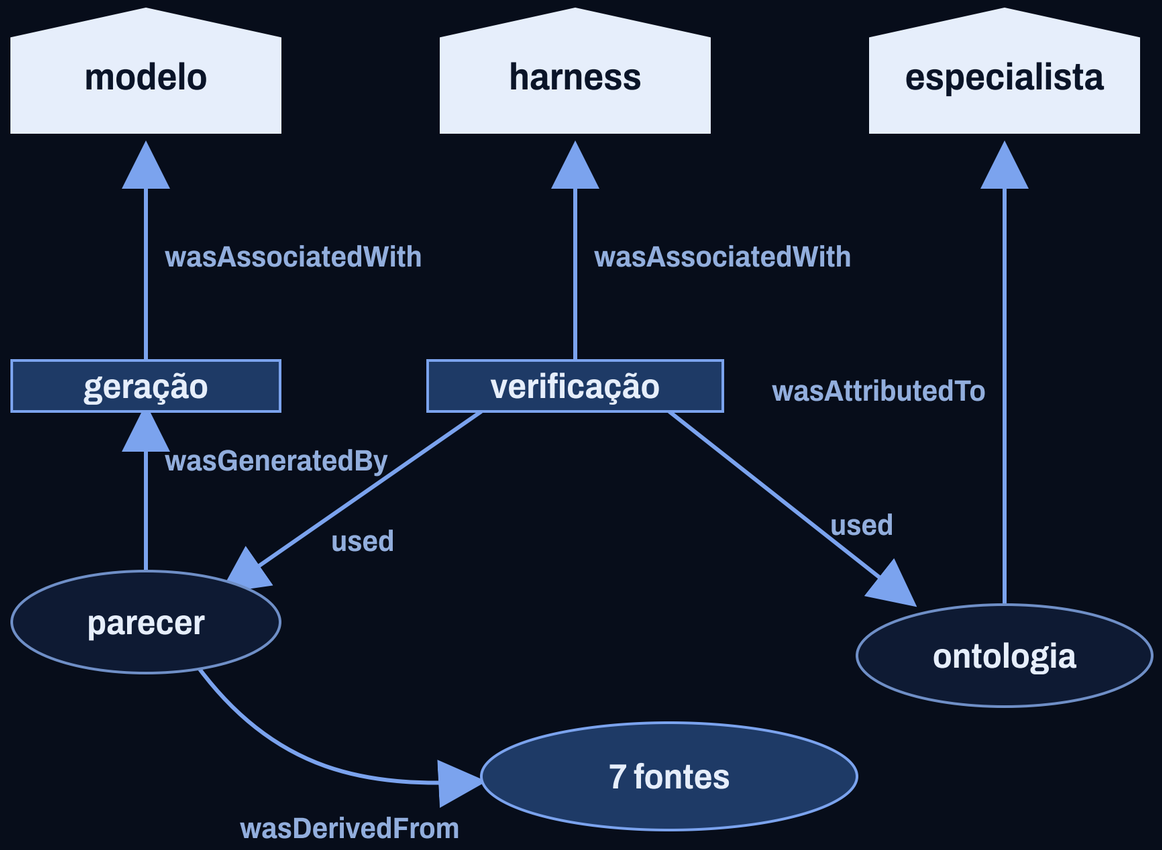
LIMPE é uma camada de avaliação jurídico-administrativa, não substitui as capacidades técnicas. Eficiência se mede, não se presume.

• Artigo: Tabela 2

Tabela 2 do artigo (Seção 2.2): síntese dos autores com base em Brasil (1988), Busuioc (2021), De Fine Licht e De Fine Licht (2020), Pádua e Lorenzetto (2024), Bollotti e Wachowicz (2024) e Tabassi (2023).

Pino T: o rastro em padrão W3C PROV

Grafo PROV-DM do parecer da demonstração (execução real de 25/10/2026).




```
"hnv:parecer-59eacca6ff47": {
 "prov:type": "hnv:Parecer",
 "hnv:sha256": "59eacca6ff47…",
 "hnv:status": "aguardando aprovação humana" },

"hnv:fonte/STF_SV13": {
 "prov:type": "hnv:Sumula",
 "prov:label": "STF, Súmula Vinculante 13",
 "hnv:statusValidacao":
  "pendente de validação" },

"wasDerivedFrom": { "_:d7": {
 "prov:generatedEntity":
  "hnv:parecer-59eacca6ff47",
 "prov:usedEntity":
  "hnv:fonte/STF_SV13" } }
```

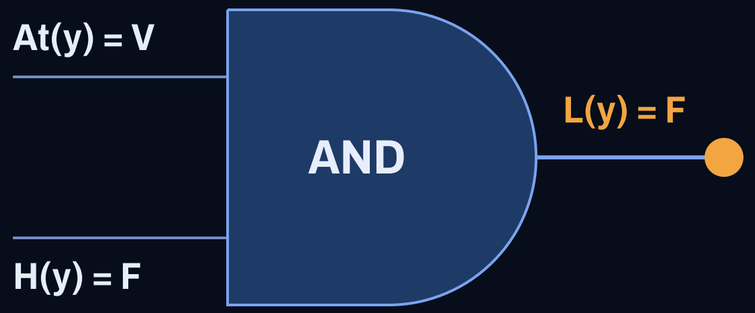
- W3C PROV-DM
- Log real (cena 2b)

Trecho abreviado de logs/prov-20261025T192704-230.json; o parecer tem 7 fontes derivadas. O nome do produto do agente foi omitido do rótulo.

Pino H: a liberação é uma decisão humana

Equação 3: a recomendação admissível só entra no resultado se a pessoa responsável decidir mantê-la.

$$L(y) = At(y) \wedge H(y)$$



At(y)	H(y)	L(y)
F	F	F
F	V	F
V	F	F: não liberado
V	V	V: liberado

Na demonstração real (cena 2b), o parecer ficou em **“aguardando aprovação humana”**: At verdadeiro, H ainda falso.

Artigo: Equação 3 | Log real (cena 2b)

F = falso, V = verdadeiro. A pessoa pode manter, modificar ou rejeitar a recomendação (artigo, Seção 3.1).

A fórmula da admissibilidade

Equação 2: uma especificação da arquitetura, não
uma garantia experimental de legalidade ou correção.

$$At(y) = E(y, R) \land N(y, \Omega) \land T(y)$$

E = suporte evidencial · N = conformidade com as regras Ω · T = rastreabilidade

O que a demonstração registrou (F = falso, V = verdadeiro)

Execução	E ∧ N ∧ T	O que o hook apontou	Resultado
Cena 2b: rascunho do modelo local	**F ∧ F ∧ F**	2 citações bloqueadas	bloqueado (exit 2)
Laço local, rodada 1	**F ∧ F ∧ F**	3 citações bloqueadas	bloqueado (exit 2)
Laço local, rodadas 2 e 3	**F ∧ V ∧ V**	3 e depois 1 citação bloqueada	bloqueado (exit 2)
Cena 2b: após a correção	**V ∧ V ∧ V**	todas as citações na ontologia	admissível; aguarda o humano

- Artigo: Equação 2
- Cena 2b
- Laço local

Valores E, N e T lidos dos logs reais de 25/10/2026 (hnv-demo). Bloqueio exige falha em ao menos um dos três.

especificação, não garantia

As regras como código e como tabela-verdade

Pseudocódigo ilustrativo das Equações 2 e 3 em lógica de regras (estilo Prolog).

```
% Y é admissível se E, N e T valem.
admissivel(Y) :- evidencia(Y),
                 norma(Y),
                 rastro(Y).

% Y é liberada se admissível e o humano aprova.
liberada(Y) :- admissivel(Y),
               humano(Y).
```

:- lê-se “se”; a vírgula é ∧ (e).

E	N	T	H	At	L
F	F	F	F	F	F
F	F	F	V	F	F
F	F	V	F	F	F
F	F	V	V	F	F
F	V	F	F	F	F
F	V	F	V	F	F
F	V	V	F	F	F
F	V	V	V	F	F

E	N	T	H	At	L
V	F	F	F	F	F
V	F	F	V	F	F
V	F	V	F	F	F
V	F	V	V	F	F
V	V	F	F	F	F
V	V	F	V	F	F
V	V	V	F	V	F
V	V	V	V	V	V

admissivel	evidencia	norma	rastro	humano	liberada
At(y)	E(y, R)	N(y, Ω)	T(y)	H(y)	L(y)

- Pseudocódigo (ilustrativo)
- Artigo: Equações 2 e 3

Tabela-verdade completa (16 linhas) calculada a partir das Equações 2 e 3. Só a linha destacada libera; em âmbar, a que é admissível mas não liberada.

pseudocódigo ilustrativo, do autor

A ponte: como a saída neural vira entrada de regras

O texto é convertido em símbolos discretos (citações) que as regras conseguem conferir.

$$y = f(x)$$

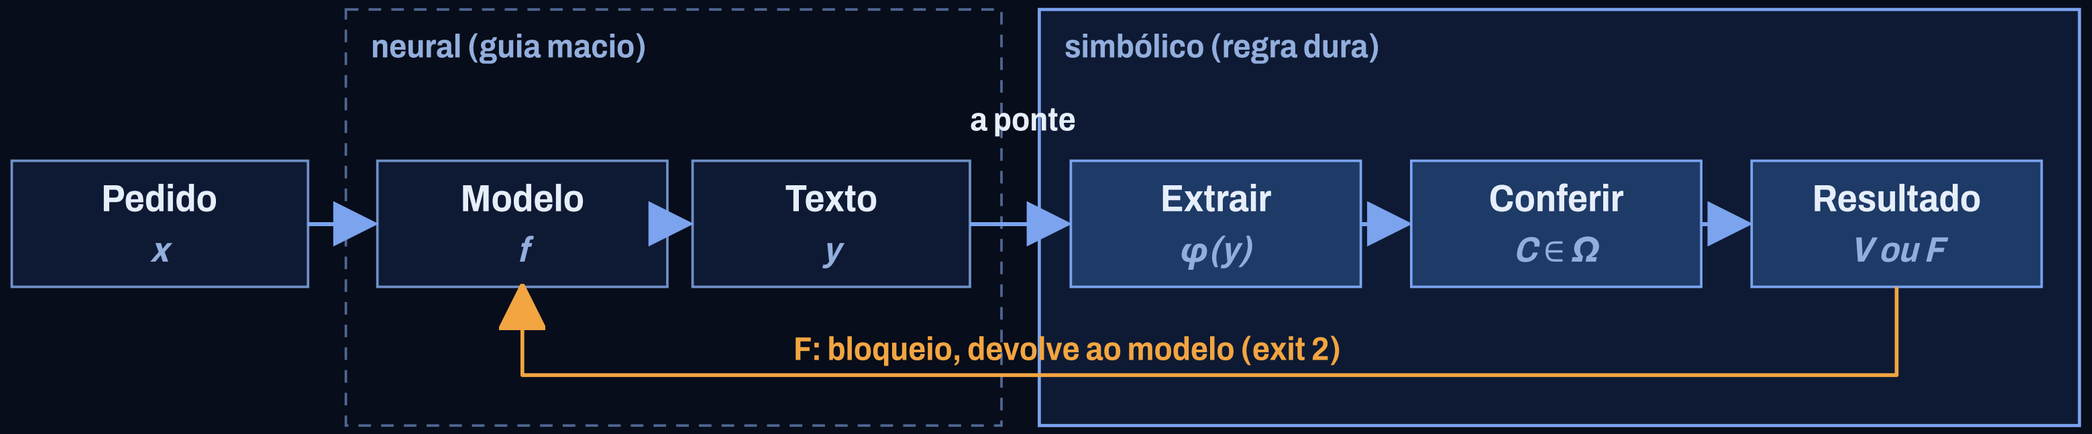
neural: texto, probabilístico

$$g(y) = N(y, \Omega) \wedge T(y)$$

simbólico: V ou F

$$(g \circ f)(x) = g(f(x))$$

composição das duas etapas



Neural: escreve em linguagem natural; a saída é uma sequência provável de palavras.

Simbólico: extrai as citações por padrões de texto, consulta uma lista fechada (a ontologia) e devolve V ou F; F bloqueia.

- Esquema (ilustrativo)
- README da demonstração
- Artigo: Equação 2

Notação g ∘ f ilustrativa, do autor deste painel: f é o modelo, g reúne a verificação e o registro. A extração φ usa padrões de texto na demonstração.

esquema ilustrativo, do autor

Três níveis de contribuição

Do modelo de governança ao sistema que o opera.

CALAIS

Modelo de governança e auditabilidade para IA verticalizada, isto é, configurada ao domínio, às suas evidências, regras e responsabilidades.

Arquitetura neurossimbólica

Traduz as condições em componentes: recuperação documental, geração neural, checagem por regras, correção, registro da origem e decisão humana.

Citāre

Artefato de referência: o sistema que hoje operacionaliza o CALAIS por meio dessa arquitetura.

Aplicações prévias informaram o design:

CBMSC
processo público-operacional

ESAG/UDESC
processo público-acadêmico de seleção

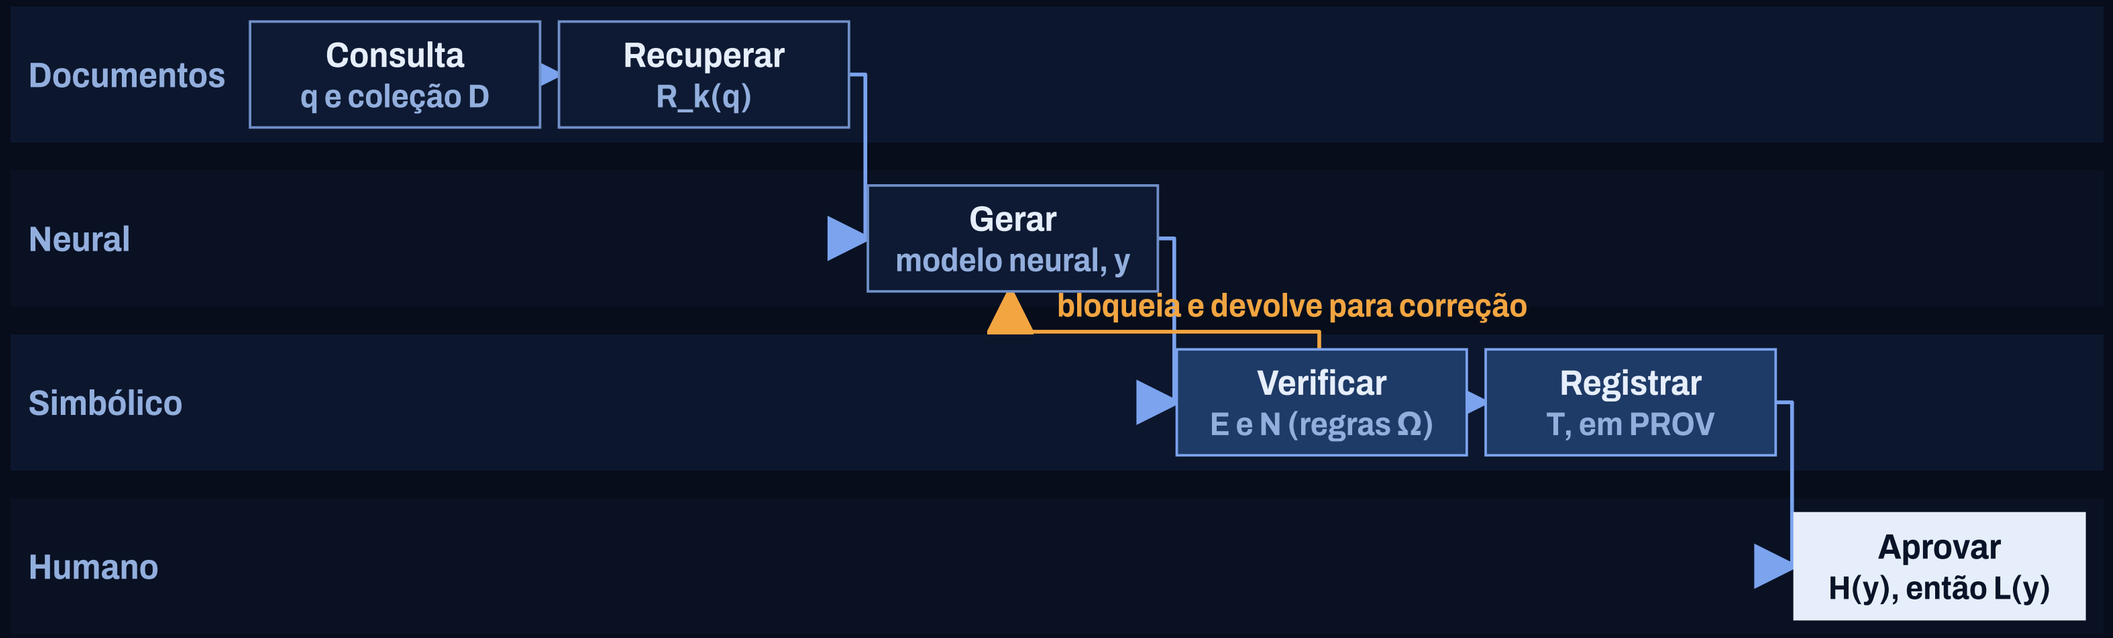
A demonstração mostra que as partes funcionam juntas; efeito e comparação com outras abordagens exigem estudo próprio.

- Artigo: Seções 1 e 3.1
- Artigo: escopo da evidência

Definição dos três níveis conforme a Introdução do artigo.

exploratório

Figura 1 redesenhada: neural propõe, simbólico verifica



Redesenho a partir da Figura 1 e da Seção 3.1 do artigo. Se a verificação encontra problema, bloqueia a resposta e a devolve para correção; a liberação depende da decisão humana.

• Artigo: Figura 1 e Seção 3.1

Redesenho do autor do painel; a figura original está no artigo. O nó “Verificar” reúne evidência (E) e norma (N); “Registrar” cobre o rastro (T).

Tabela 3: seis ciclos de Design Science Research



Ciclo	Atividade realizada	Evidência ou produto
Problema	Análise de processos decisórios com uso intensivo de documentos	Necessidade de evidência, regra, rastro e decisão humana
Requisitos	Levantamento com documentos e especialistas do domínio	Requisitos funcionais e salvaguardas
Design	Integração de RAG, regras, logs e revisão humana	Arquitetura e fluxo de decisão
Demonstração	Aplicação no CBMSC e versão derivada na ESAG/UDESC	Registros dos dois contextos
Avaliação	Análise descritiva de uso, carga percebida e ocorrências	Tabelas, logs e respostas ao Raw NASA-TLX
Refinamento	Ajustes derivados da aplicação e da revisão por especialistas	Evolução do artefato e de suas regras

Artigo: Tabela 3

Fonte do artigo: elaborada pelo autor com base em Peffers et al. (2007), adaptando a sequência às atividades efetivamente realizadas.

Triplas da ontologia e a recuperação (Equação 1)

Sujeito, predicado e objeto: o formato de dados em RDF/OWL.

Sujeito	Predicado	Objeto
:Artigo42	a	:Artigo
:Artigo42	:temSecao	:Introducao
:Introducao	:contem	:Paragrafo4
:Paragrafo4	:expressa	:A1
:A1	:temCitacao	:CitSilva2022
:CitSilva2022	:identifica	:ObraSilva2022
:ObraSilva2022	:temCopiaEm	:PDFSilva2022
:PDFSilva2022	:contem	:Trecho_p4
:Trecho_p4	:podeApoiar	:A1
:Auditoria7	:confere	:PDFSilva2022
:Auditoria7	:produzResultado	:EvidenceReady

$$R_k(q) = TopK_{d \in D}\, s(q, d)$$

A recuperação (Eq. 1) traz trechos candidatos. A tripla destacada só passa a valer depois da validação: estar no mesmo PDF não basta.

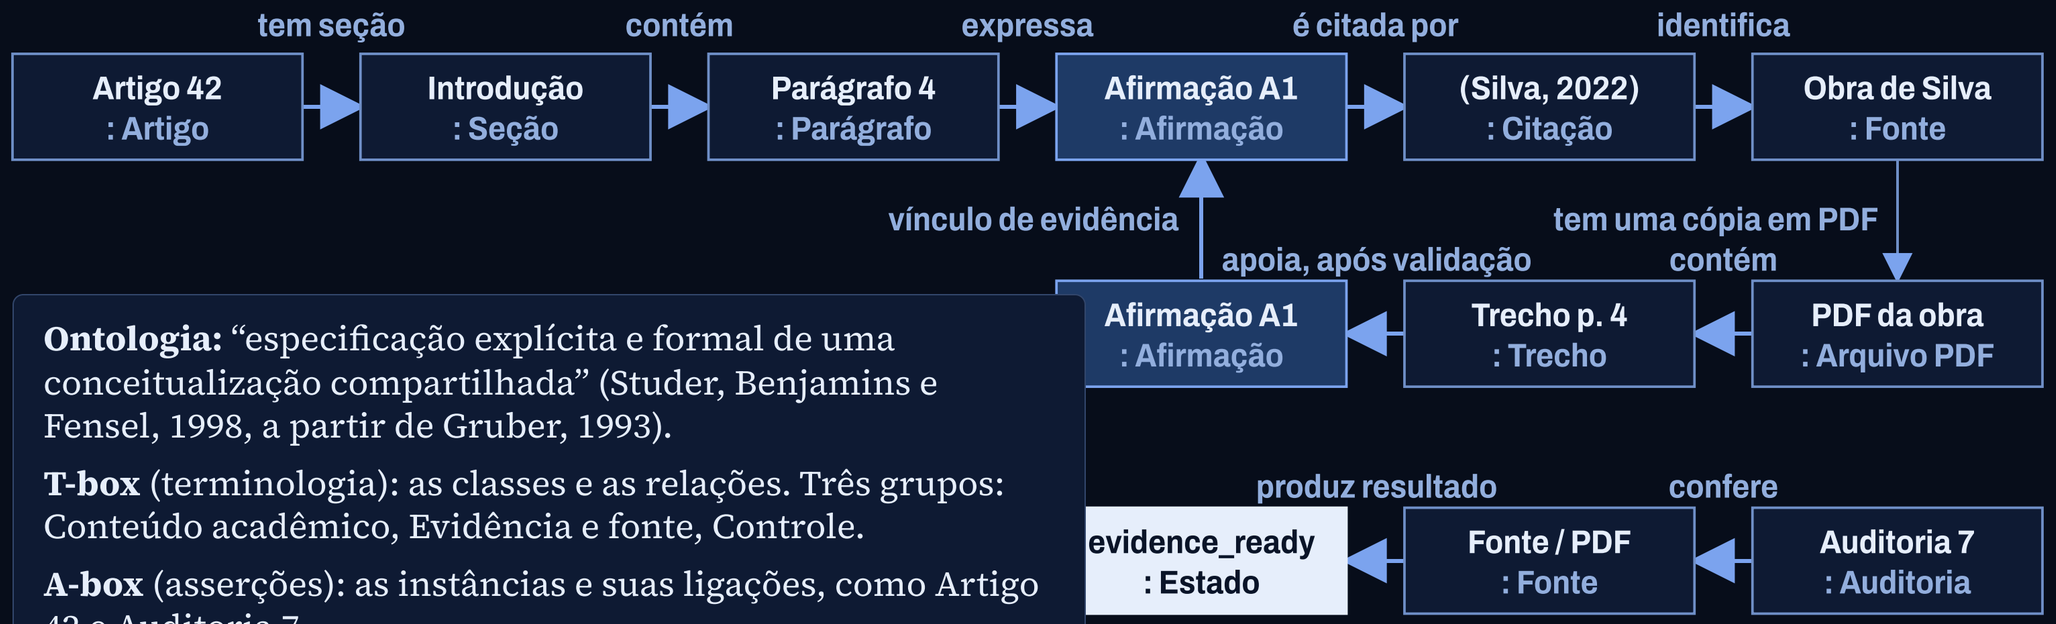
Modelagem do autor do painel a partir da Atividade v05; os nomes dos predicados são adaptados e a instância (Silva, 2022) é fictícia.

- Ontologia do Citāre (v05)
- Artigo: Equação 1
- Triplas (ilustrativas)

Notação Turtle simplificada: “a” significa “é instância de”. Dados do CBMSC/ESAG não avaliam o Citāre.

triplas ilustrativas, do autor

A ontologia do Citāre: classes e instâncias



Ontologia: "especificação explícita e formal de uma conceitualização compartilhada" (Studer, Benjamins e Fensel, 1998, a partir de Gruber, 1993).

T-box (terminologia): as classes e as relações. Três grupos: Conteúdo acadêmico, Evidência e fonte, Controle.

A-box (asserções): as instâncias e suas ligações, como Artigo 42 e Auditoria 7.

Dados do CBMSC/ESAG não avaliam o Citāre. Instâncias do desenho são fictícias, para ensinar a leitura.

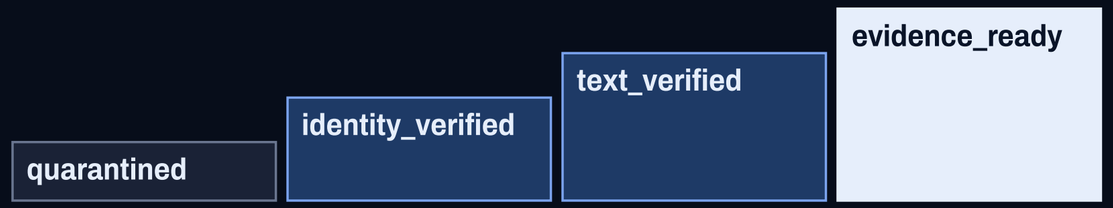
- Ontologia do Citāre (v05)
- Studer et al. (1998)
- Artigo: declaração de uso

Atividade 1 de Desenvolvimento de Ontologias, v05 (30/09/2026). O desenho reproduz a cadeia e a árvore da atividade; as classes intermediárias são didáticas.

material didático

Autoria, ano e DOI; os quatro estados da fonte

Estado da fonte no Citāre



- quarantined: dado ausente, não confirmado ou divergente
- identity_verified: obra identificada; origem do texto ainda não
- text_verified: pode ser anexada ao artigo
- evidence_ready: trecho validado ligado a uma afirmação

A exportação formal bloqueia na etapa

bibliographic_match
o marcador não achou a obra certa entre as fontes do artigo

recovery
a recuperação do PDF falhou

source_audit
fonte em quarentena ou sem auditoria atual

exact_evidence
falta o vínculo desta afirmação exata ao trecho

autoria | ano | DOI — o marcador (Silva, 2022) precisa corresponder a uma obra registrada; o DOI identifica cada obra

Declaração de uso de IA do artigo: o autor usou o Citāre, plataforma de assessoria acadêmica com supervisão humana, para apoiar a redação e a verificação de citações; o texto foi guiado pelas fontes da coleção do autor (RAG), com regras de autoria, ano e DOI. Todo conteúdo e toda citação sugeridos foram revisados e aprovados pelo autor, que assume plena responsabilidade, sem atribuir autoria à IA.

Dados do CBMSC/ESAG não avaliam o Citāre.

- Artigo: declaração de uso de IA
- Ontologia do Citāre (v05)

Declaração traduzida do artigo (seção “AI use disclosure”). Estados e etapas: Atividade de Ontologia v05.

material didático

CBMSC: o que os logs de envio mostram

Janeiro a agosto de 2026, artefato de envio de mensagens.

9.054
registros de envio

191
dias, de 28/01 a 07/08/2026

2.813
envios sem sucesso



Cinza: 2.813 sem sucesso (31,1% dos 9.054). Azul: os demais 6.241 (diferença, cálculo do autor). Sem sucesso não é bloqueio.

137
falhas de conexão

143
estados close

1.018
erros de aquecimento

Processos diferentes, não somados. Nenhum evento classificado como banimento ou restrição de linha pela Meta foi localizado. Isso não é risco zero: não há campo exclusivo para detectar todo banimento.

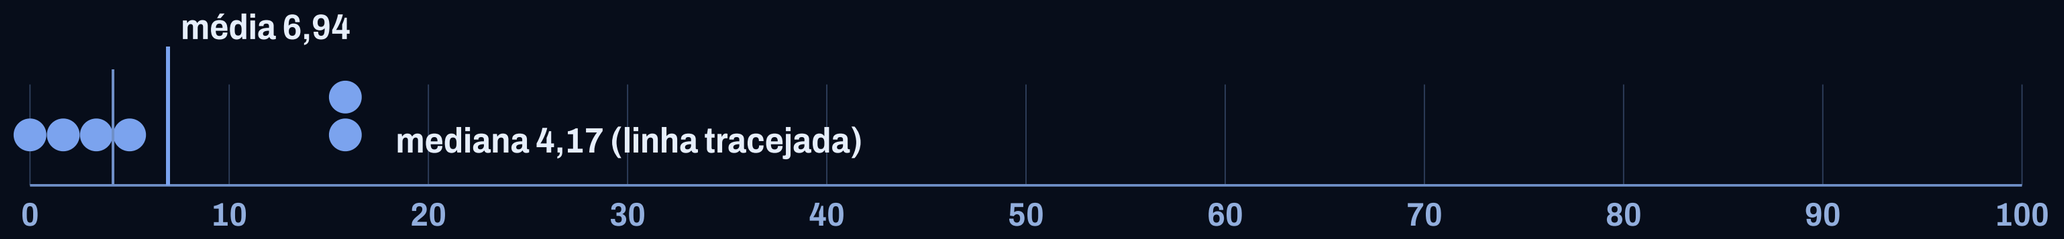
- Artigo: logs do CBMSC
- Artigo: escopo

Seção 4.1 do artigo. Calendário sem dado por dia: o artigo informa só o total do período.

exploratório, SC

NASA-TLX bruto: seis registros de tarefas

Escala de 0 a 100: quanto menor, menor a carga percebida.



Registro	Tarefa	Pontuação
R1	Salvar análise de entrevista	15,83
R2	Salvar regras de decisão	15,83
R3	Salvar diagrama BPMN	5,00
R4	Salvar diagrama BPMN	3,33
R5	Salvar diagrama BPMN	1,67
R6	Salvar diagrama BPMN	0,00

Como ler

- São **tarefas, não pessoas**: seis registros, dois identificadores.
- Cinco registros vêm da mesma conta, logo não são independentes.
- Sem comparação manual e sem inferência populacional.
- O zero foi mantido: a tabela e a auditoria confirmaram o envio.

- Artigo: Tabela 5
- Hart e Staveland (1988)

Média 6,94; mediana 4,17; faixa 0,00 a 15,83 (Raw NASA-TLX = média simples de seis dimensões).

experiência

Tabela 4: o que cada caso permite afirmar

Evidência delimitada: contextos, etapas e medidas diferentes.

Dimensão	CBMSC	ESAG/UDESC
Contexto	Processo público-operacional	Processo público-acadêmico de seleção
Etapa	Operação assistida observada	Versão derivada em fase beta
Raw NASA-TLX	● Seis registros associados a dois identificadores	○ Não identificado no material analisado
Logs de operação	● Disponíveis para envio de mensagens, infraestrutura e aquecimento	○ Nenhuma medida diretamente comparável identificada
Salvaguardas comuns	Documentos, regras e decisão humana	Documentos, regras e decisão humana

● disponível · ○ não identificado. Os dois casos não são comparados quantitativamente e não avaliam o Citāre.

• Artigo: Tabela 4 • Artigo: escopo

Tabela 4 do artigo (Seção 4.1), traduzida. ESAG/UDESC: versão beta; não foram identificadas medidas comparáveis.

Replay da execução real

Gerado só a partir dos logs de 25/10/2026; cerca de 87 segundos.

```
$ agente -p "O modelo local da prefeitura gerou um rascunho de parece...

● Read(logs/cena1/parecer_cena1_rodada2.md)
● Skill(parecer-administrativo)
● Read(ontologia/fontes.json)
● Write(saida/parecer-rascunho-local.md)
  └ hook PostToolUse:Write → exit 2
```

Bloqueio — Bloqueio: a regra dura devolve o erro ao modelo (exit 2)

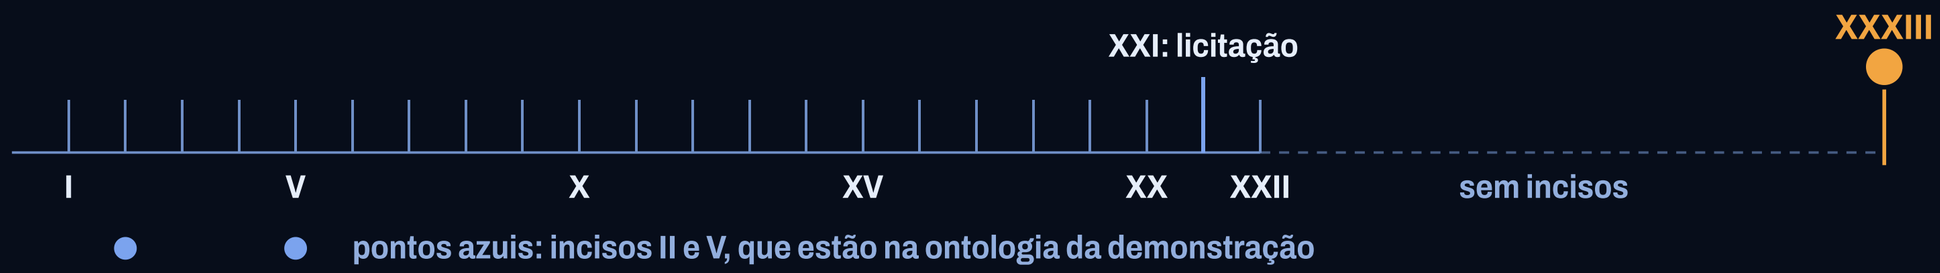
- Log real (cena 2b)
- Laço local
- Cena 1

Espaço pausa; R reinicia. Os logs foram sanitizados (a lista de ferramentas pessoais saiu); o nome do produto do agente foi omitido nesta cópia.

ilustrativa, execução real, 25/10/2026

Régua do art. 37: onde o modelo errou

O artigo 37 da Constituição tem 22 incisos; o modelo citou o XXXIII.



Rodada 1

art. 37, XXXIII

inciso inexistente

Rodada 2

art. 37, XXXIII

Decreto 4.653/2002

decisão do STJ sem número

Rodada 3

art. 37, XXI, “proíbe o nepotismo”

Lei 8.112/1990

ADI 2.958

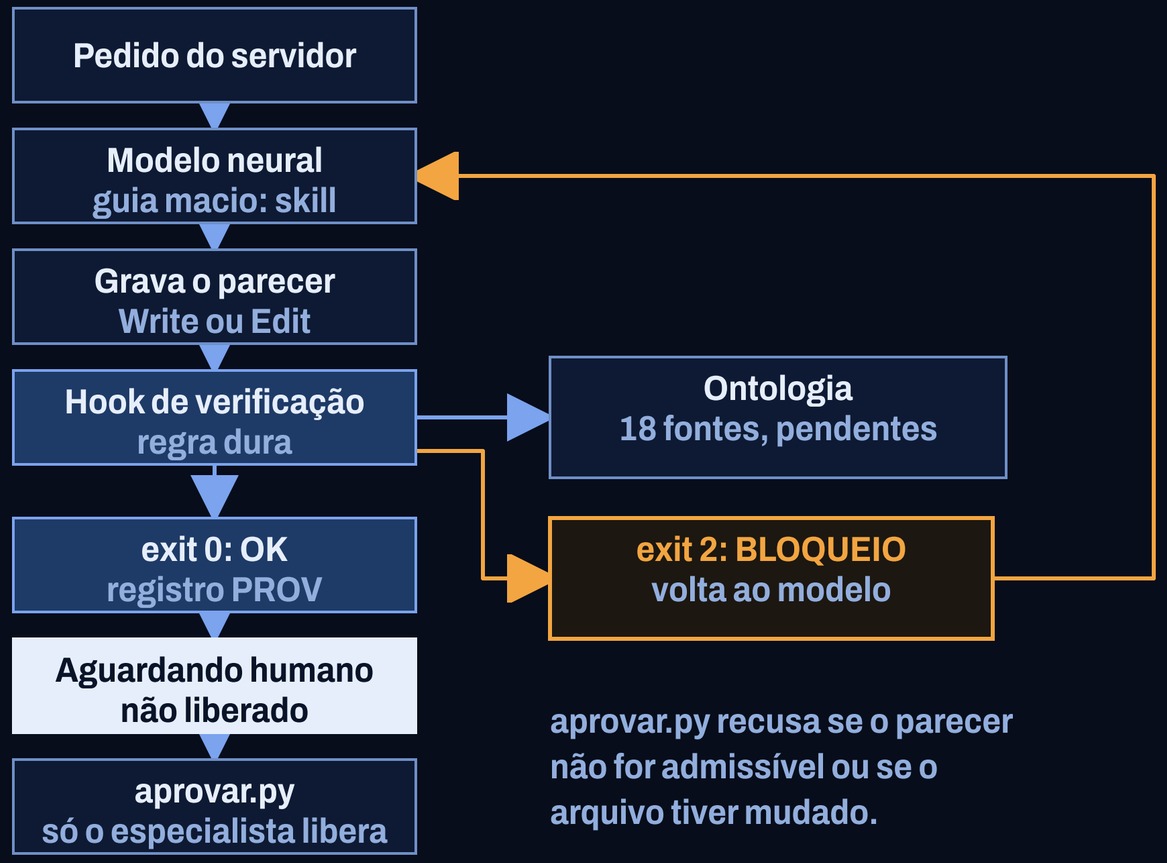
Em âmbar: inexistente ou com conteúdo falso. **Em cinza-azulado:** real, mas sem base ou não conferível. XXXIII só aparece nas rodadas 1 e 2.

- Checagem manual (cena 1)
- Constituição, art. 37

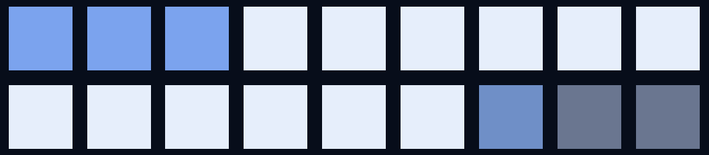
Fontes: checagem manual de 25/10/2026 e texto do art. 37 no Planalto. Modelo local de 3 bilhões de parâmetros, sem harness.

O portão: do pedido à aprovação humana

Fluxo da demonstração (README) e o que ela não faz.



Ontologia da demonstração: 18 fontes



3 normas · 12 dispositivos · 1 súmula · 2 precedentes

Limites

- **Confere citações, não raciocínio.**
- **Bloqueado não é falso:** a Resolução 7/2005 existe, mas está fora da ontologia.
- Referência vaga (“uma decisão do STJ”) escapa.
- A cena 2b é induzida: o rascunho do modelo local foi entregue ao agente.

- README da demonstração
- Ontologia (18 fontes)
- Laço local

Laço local: citações bloqueadas 3, 3 e 1; encerrou como “bloqueado após o limite de rodadas”. Fluxo conforme o README (25/10/2026).

pendente de validação

O rastro do parecer: registro em W3C PROV

Relatório de verificação do parecer da cena 2b (execução real).

aguardando aprovação humana

Campo do registro	Valor
evidência	V
norma	V
rastreabilidade	V
admissibilidade	V
aprovação humana	F
liberação	F

Verificação em 17 ms. Parecer sha256 59eacca6ff47…; ontologia 0.1.0, sha256 5b1f9baf096c…

Citações resolvidas na ontologia: 9, sobre 7 fontes

Citação no parecer	Fonte da ontologia	Status
CF/88, art. 37, caput	CF88_art37_caput	ok
CF/88, art. 37, V	CF88_art37_V	ok
STF, Súmula Vinculante 13 (2 vezes)	STF_SV13	ok
STF, RE 579.951	STF_RE579951	ok
Lei 8.429/1992, art. 11, XI (2 vezes)	LEI8429_art11_XI	ok
CF/88, art. 37, § 4º	CF88_art37_par4	ok
Decreto 7.203/2010, art. 2º, III	DEC7203_art2_III	ok

- Log real (cena 2b)
- W3C PROV-DM
- Ontologia (18 fontes)

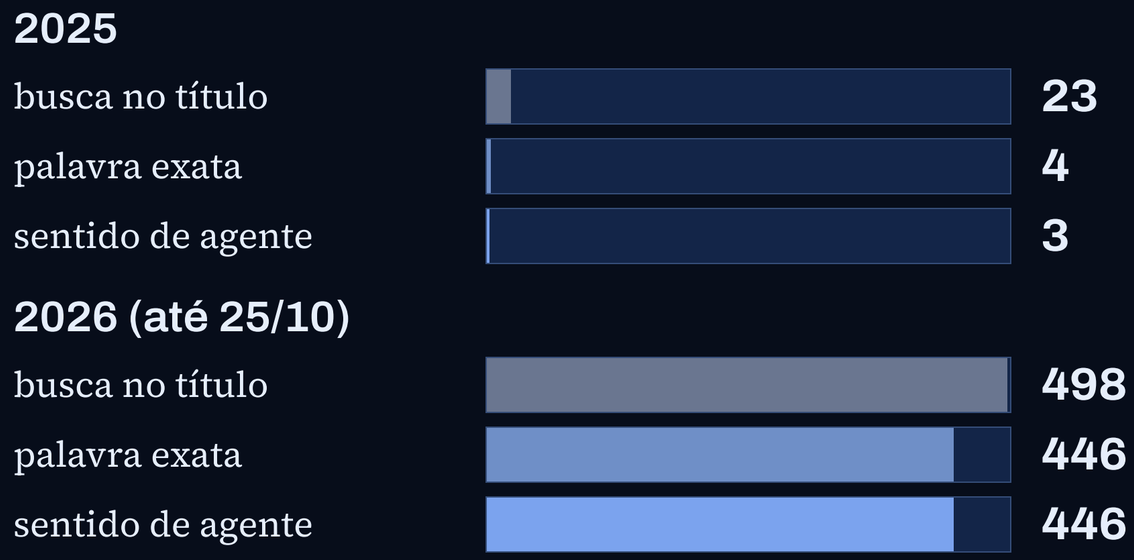
Dados de logs/prov-20261025T192704-230.json. A máquina declara “admissível”; só a pessoa libera.

pendente de validação

Como foi feita a contagem de “harness” no arXiv

Contagem do autor em 25/10/2026, pela API pública; não é revisão sistemática.

1. Busca: título com “harness”, na API do arXiv.
2. Filtro: só a palavra exata (a busca também traz “harnessing”).
3. Sentido: 2025 conferido título a título; 2026 por amostra de 25 títulos, todos de agentes.



Em 2023 e 2024, a palavra exata não aparece. 2026 é parcial.

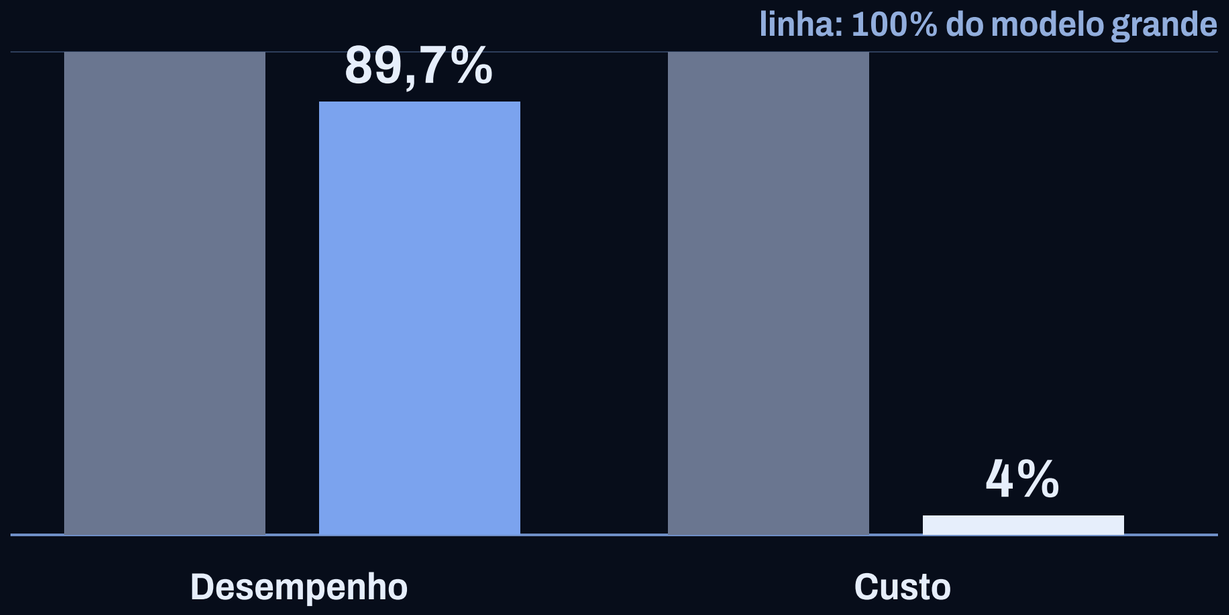
Contagem do autor (arXiv)

Consulta: ti:harness (e abs:agent); contagens feitas em 25/10/2026. Número de 2026 depende de a amostra de 25 títulos representar o conjunto.

contagem do autor

Modelo pequeno com bom harness

Yang, Zhao, Wu e Kästner (2026), arXiv 2607.08938



modelo grande = 100%

modelo pequeno com harness adaptado: **89,7%** do desempenho a **4%** do custo

Título: “Better Harnesses, Smaller Models: Building 90% Cheaper Agents via Automated Harness Adaptation”.

Yang et al. (2026)

Frase do resumo: “recovering 89.7% of LLM performance at 4% of the cost”. Resultado do trabalho citado, não replicado aqui.

preprint, arXiv

Contexto: do investimento ao harness

Capex de Microsoft, Alphabet, Amazon e Meta

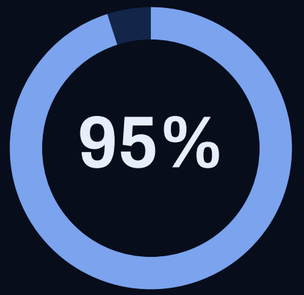
2025 · cerca de US$ 410 bi



2026 · cerca de US$ 725 bi (previsão)



Faixa citada para 2026: US$ 695 a 750 bi; é orientação das empresas, não valor realizado.

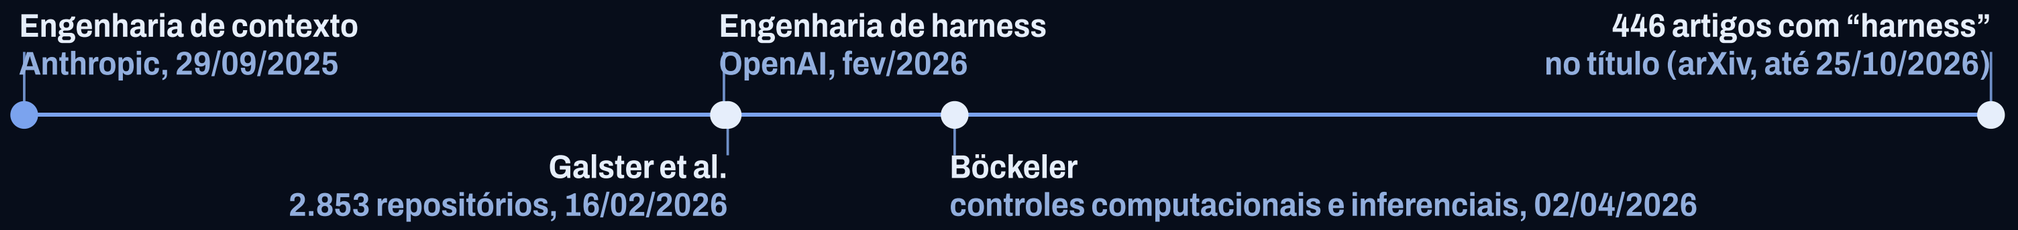


Sem retorno mensurável

das organizações (MIT NANDA, 2025)

Mais de 300 iniciativas, 52 entrevistas e 153 líderes.

Da engenharia de contexto (2025) à engenharia de harness (2026)

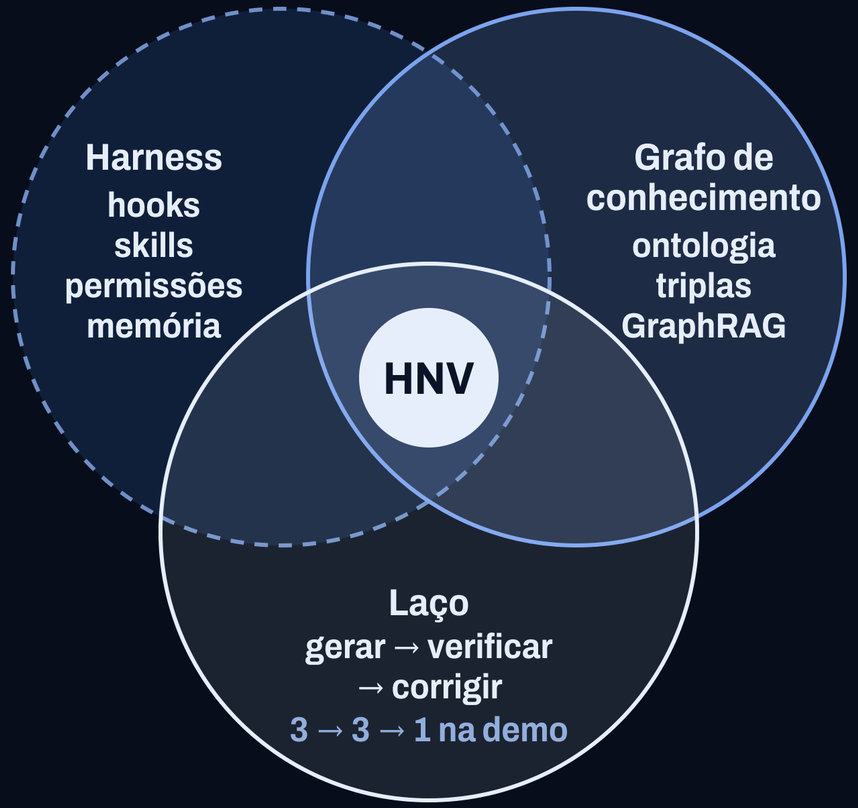


- Engenharia de contexto (2025)
- OpenAI (2026)
- Galster et al. (2026)
- Böckeler (2026)
- Contagem arXiv
- Capex (CNBC)
- MIT NANDA

Capex é previsão de imprensa; o MIT é preliminar; a contagem é do autor. A página da OpenAI respondeu 403 na conferência, por isso o selo.

preliminar imprensa

Harness, grafo de conhecimento e laço: o HNV na interseção



Laço = ciclo agêntico. Não é uma disciplina consagrada: é o mecanismo da demonstração.

Peça do harness	Camada	Papel
Skill e instruções do projeto	guia **macio** (inferencial)	orienta o modelo: formato do parecer, citar só a ontologia
Hook e verificador de citações	regra **dura** (computacional)	bloqueia citação fora da ontologia (exit 2)
Ontologia de fontes	conhecimento **simbólico** do especialista	fontes reais conferidas nas páginas oficiais
Registros PROV	**rastreabilidade**	quem gerou, o que foi usado, de que fontes deriva
Aprovação (aprovar.py)	**liberação**	só o especialista libera; a máquina declara, no máximo, “admissível”

Böckeler (2026) separa controles **computacionais** (rápidos, como testes e linters) e **inferenciais** (revisão por modelo), e cada um pode ser guia (antes) ou sensor (depois). Aqui, a skill é guia inferencial e o hook é sensor computacional.

README da demonstração · Böckeler (2026) · Galster et al. (2026) · Edge et al. (2024) · Laço local

Mapa do README (25/10/2026). GraphRAG: um modelo extrai um grafo de entidades dos documentos (Edge et al., 2024). Laço local: citações bloqueadas 3, 3 e 1.

hipótese: o HNV não foi testado

O núcleo: uma camada simbólica sobre o modelo

O especialista escreve as regras e a ontologia do domínio.

Modelo neural

interpreta linguagem natural e escreve o rascunho



Camada simbólica vertical

ontologia do domínio | regras (hooks) | rastro PROV | portão humano

“Vertical” significa específica de um domínio, como o Direito Administrativo na demonstração.

Componente	Na demonstração	O que ainda falta
Guia macio	skill e instruções do projeto	—
Regra dura	hook e verificador por padrões de texto	referências vagas escapam; não é um analisador jurídico completo
Ontologia do domínio	18 fontes conferidas nas páginas oficiais	validação pelo especialista (hoje, “pendente”)
Rastro e portão	registro PROV e aprovar.py	—

- Ontologia (18 fontes)
- README: limitações

Limitações conforme o README da demonstração. O HNV é uma hipótese ainda não testada.

hipótese

Domínios candidatos

Propostas: onde um especialista poderia escrever a ontologia e a regra, com a pessoa certa no portão final.

Pareceres administrativos

Demonstração de 25/10/2026; ontologia de 18 fontes, pendente de validação.

quem libera: o especialista que aprova

Escrita científica

Citāre: ontologia operacional descrita na Atividade v05; o artigo teve as citações conferidas nele, com revisão humana.

quem libera: o autor, que assume a responsabilidade

Boletins de ocorrência de bombeiros

Ideia surgida na aula de ontologias; não implementada.

quem libera: a definir

Finanças reguladas (antifraude)

Registrar sinais, fontes, regras, exceções e revisão humana antes das decisões; exige adaptação regulatória e validação empírica.

quem libera: revisão humana

- Ontologia (18 fontes)
- Artigo: uso do Citāre
- Artigo: transferência (Seção 4.2)

Boletins de ocorrência: proposta da aula de ontologias, sem fonte publicada. Finanças: hipótese citada no artigo.

hipóteses distintas são propostas

O estudo pareado: quatro condições, sete medidas

Desenho previsto nos trabalhos futuros do artigo. Nada disso foi medido ainda.

Condição	Fidelidade de citação	Conformidade	Qualidade da decisão	Tempo	Custo	Retrabalho	Intervenções humanas
Manual	○	○	○	○	○	○	○
LLM puro	○	○	○	○	○	○	○
RAG	○	○	○	○	○	○	○
Arquitetura completa	○	○	○	○	○	○	○

- tarefas equivalentes nas quatro condições
- critérios definidos antes da coleta
- participantes com códigos distintos
- comparação entre condição manual e assistida

• Artigo: Seções 3.2, 4.2 e 5

Condições e medidas conforme os trabalhos futuros do artigo (Seção 5). ○ = medida planejada.

planejado, não medido

Cinco limites, ditos antes de a pergunta chegar

Situado em Santa Catarina

A validade externa se limita aos processos observados; a evidência é exploratória e descritiva.

fonte

Seis registros são tarefas, não pessoas

Cinco vêm da mesma conta; não há comparação manual. Os dados do CBMSC e da ESAG não avaliam o Citāre.

fonte

Confere citações, não raciocínio

Bloqueado não é falso: a Resolução 7/2005 existe, mas está fora da ontologia.

fonte

Ontologia da demonstração pendente

As 18 fontes ainda aguardam a validação do especialista (selo: pendente de validação).

fonte

O HNV é uma hipótese

O harness neurossimbólico vertical ainda não foi testado; o próximo passo é o estudo pareado.

fonte

- Artigo: escopo
- Ontologia (18 fontes)

Limites conforme o artigo (Seções 3.2, 4.2 e 5) e o README da demonstração.

hipótese de validação